



内蒙古大学
INNER MONGOLIA UNIVERSITY

《深度学习》设计报告

学院 : 电子信息工程学院

年级 : 2023 级

专业 : 通信工程（产教融合）

姓名 :

学号 :

日期 : 2026 年 5 月 12 日

目 录

一、摘要与核心算法数学契约	3
1.1 核心算法设计与数学契约	3
二、数据集划分、实验环境与评价体系	4
2.1 严谨的三阶段子集划分（避免数据泄漏）	4
2.2 软硬件运行环境与依赖	4
2.3 多维客观评价指标体系	4
三、分批向量化 kNN 实现与微基准效率分析	5
3.1 核心算法实现摘录（core.py）	5
3.2 距离计算微基准对比与加速分析	5
3.3 与 scikit-learn 交叉验证对照	5
四、100 组网格搜索：超参数 k 与特征表现规律	6
4.1 典型配置验证准确率对比	6
4.2 超参数敏感度与消融分析	6
五、图像特征探索：SVD PCA 降维与局部梯度 HOG	7
5.1 五种特征提取方案验证表现对比	7
5.2 特征表征能力与计算复杂度权衡	7
六、完整测试集评估（10,000 张）与逐类性能诊断	8
6.1 最终测试综合指标汇总	8
6.2 逐类别详细分类报告 (Precision / Recall / F1)	8
七、混淆矩阵深入诊断与误分类案例归因	9
7.1 典型误分类样本与训练集近邻对比原图	9
7.2 高频有向混淆形态学成因与算法局限性探讨	9
八、总结讨论、QA 验证、工程复现与开源系统	10
8.1 算法单元测试与科学性验证	10
8.2 作业工程复现指南	10
8.3 开源工程仓库与在线交互报告系统	10

一、摘要与核心算法数学契约

本报告基于经典非参数模式识别算法——k 近邻 (k-Nearest Neighbors, kNN)，针对 MNIST 手写体数字图像分类任务展开全面系统的工程实现与评估。传统 kNN 训练零开销但推理计算量巨大，本项目完整实现了中心化 SVD PCA 降维、HOG 局部特征提取及分批向量化距离检索算法。

实验遵循三阶段无泄漏划分原则：从 60,000 张训练集中抽取 12,000 张训练子集与 2,000 张独立验证子集进行 100 组超参数网格搜索；锁定最优配置后，使用全部 60,000 张训练样本拟合并在独立的 10,000 张全量测试集上进行最终评测。

1.1 核心算法设计与数学契约

采用矩阵代数展开的分批向量化公式消除循环开销，并对负值截断满足距离公理：

$$\|\mathbf{q} - \mathbf{x}\|_2^2 = \|\mathbf{q}\|_2^2 + \|\mathbf{x}\|_2^2 - 2\mathbf{q}\mathbf{x}^T \quad (\text{式 1})$$

在距离加权投票模式中，加权系数定义为距离倒数（零距离近邻独享投票权）：

$$w_i = \frac{1}{\|\mathbf{q} - \mathbf{x}_i\|_2} \quad (\text{式 2})$$

最终多数票决策目标函数如下：

$$\hat{y} = \arg \max_{c \in \{0, \dots, 9\}} \sum_{i=1}^k w_i \cdot \mathbb{I}(y_i = c) \quad (\text{式 3})$$

- 确定性双层平票仲裁：近邻检索并列优先保留训练行号较小样本；多数票统计并列严格判定为类别编号较小者（0-9），契合课程标准。

- Top-n 精度口径：按投票得分降序、类别编号升序排序，未获票类别得分归零后按编号补位，避免虚构高置信候选。

关键词：MNIST 手写体；k 近邻分类器；SVD PCA；HOG 梯度特征；分批向量化；Top-n 精度

二、数据集划分、实验环境与评价体系

实验采用标准 MNIST 手写体数字数据集，每张图像为 28×28 灰度图（784 维原始特征，标签 0-9），像素除以 255 归一化。原始 IDX 格式无损转换，哈希清单记录于 data_manifest.json，杜绝重采样偏差。

2.1 严谨的三阶段子集划分（避免数据泄漏）

以固定随机种子（42/43）从 60,000 张训练集分层抽取 12,000 张训练与 2,000 张验证子集（每类训练 1,200、验证 200 张，索引无交集）。PCA 投影基仅在 12,000 训练子集拟合，验证集仅映射。最终测试集（10,000 张）在锁定配置前保持完全盲态。

2.2 软硬件运行环境

环境组件	配置与版本	功能说明
操作系统 / 处理器	Windows 11 / x64 多核 CPU	负责数据预处理与特征工程调度
图形加速卡 GPU	NVIDIA GeForce RTX 4080 Laptop GPU	用于分批向量化欧氏距离矩阵高速检索
核心依赖库	PyTorch 2.2 / CUDA / NumPy 1.26 / scikit-learn	统一矩阵运算后端与严格 QA 交叉对照
特征处理库	scikit-image 0.22	用于提取 324 维 HOG 局部方向梯度特征

2.3 评价指标体系

建立多维客观评价指标：Top-1 准确率、Top-3/Top-5 覆盖率（真实标签出现在前 3/5 个候选类的比例）、10×10 混淆矩阵，以及宏平均 Macro-F1（平衡各类精度）。精确测时特征变换、近邻检索与投票过程。

- 科学评估防泄漏原则：在整个 100 组网格搜索探索阶段，全量 10,000 张独立测试集完全保持不可见；特征工程（如 PCA 均值向量与投影基矩阵）严格仅在 12,000 张训练子集上拟合，验证集与测试集仅应用已训练变换，杜绝任何形式的全局统计信息泄露。

三、分批向量化 kNN 实现与微基准效率分析

传统 kNN 算法若直接使用双重循环遍历 $10,000 \times 60,000$ 样本对，需 4.7 亿次浮点运算，耗时达数十分钟以上。本项目采用分批向量化（64 查询/批），利用矩阵乘法一次性求解批次距离，显存可控且吞吐量极高。

3.1 核心算法实现摘录（core.py）

核心函数与向量化代码摘录	执行逻辑与算法优化说明
<code>for start in range(0, len(query), batch):</code>	分批滑动切片，限制单批显存与内存峰值占用
<code>d = ((b*b).sum(1)[None,:] + norm[None,:]) - 2*b@a.T).clamp_min(0)</code>	GPU 矩阵广播计算欧氏平方距离，截断微小负值
<code>ix = np.argpartition(d, k-1, axis=1)[:k]</code>	快速选择算法筛选前 k 个近邻，复杂度从 $O(N \log N)$ 降至 $O(N)$
<code>order = np.lexsort((ix, vals), axis=1)</code>	字典序双键排序，彻底解决距离平票时的确定性行号决选

3.2 距离计算微基准对比（同一 CPU 数据集，3 次中位数）

计算方法	样本规模（查询×训练×维度）	中位数耗时（秒）	相对加速比
Python 原生双重循环	$32 \times 240 \times 24$ 维	0.04412120 s	1.0× (基准)
NumPy 广播矩阵向量化	$32 \times 240 \times 24$ 维	0.00002820 s	1564.6× (极大加速)

3.3 与 scikit-learn 独立实现交叉核对

在同一划分上针对 10 组配置与 `KNeighborsClassifier(algorithm='brute')` 进行独立对照，2,000 条验证预测完全一致（一致率严格达到 100.00%），证明自编逻辑的数值可靠性。

四、100 组网格搜索：超参数 k 与特征表现规律

实验在 5 种特征 × 2 种距离 × 2 种加权 × 5 个 k 值下完成 100 组验证实验。下图展示同一验证划分在 L2 距离与均匀投票下的 Top-1 曲线。




图 1：不同 k 值与特征空间在验证集上的 Top-1 准确率曲线

4.1 典型配置验证准确率对比表

特征空间	维度	k=1	k=3	k=5（锁定）	k=7	k=9
Raw 像素	784	94.80%	94.80%	94.85%	94.75%	94.50%
PCA-20	20	94.85%	94.90%	94.95%	94.95%	94.70%
PCA-50	50	95.70%	95.55%	95.50%	95.30%	95.20%
PCA-100	100	95.30%	95.25%	95.25%	95.10%	95.05%
HOG 特征	324	95.60%	95.85%	96.00%	95.85%	95.85%

4.2 超参数敏感性与消融分析

- k 值敏感度：k=1 时易受孤立噪点影响发生过拟合；k 过大（k=7,9）决策面过度平滑导致欠拟合。在 HOG 特征下，k=5 取得 96.00% 最高验证率，有效平衡了局部判别力与抗噪鲁棒性。

- 距离度量与加权对比：欧氏距离（L2）在连续梯度空间中的判别边界更为平滑，平均准确率略高于曼哈顿距离；当 k 增至 7 或 9 时，距离倒数加权赋予最近邻更高置信度，有效抑制了远距离边界样本的投票干扰。

五、图像特征探索：SVD PCA 降维与局部梯度 HOG

自主实现的中心化 SVD PCA 仅使用训练子集分解。前 20 维保留 63.8% 方差；前 50 维保留 82.5% 方差；前 100 维保留 91.4% 方差。




图 2：SVD PCA 主成分解释方差累计分布曲线（训练子集拟合）

5.1 特征方案最高验证准确率对比

特征提取方案	特征维度	最佳 k	最佳加权	最高验证准确率
Raw 原始灰度像素	784	k=5	距离加权	94.85%
SVD PCA 降维 (20 维)	20	k=5	距离加权	94.95%
SVD PCA 降维 (100 维)	100	k=1	均匀投票	95.30%
SVD PCA 降维 (50 维)	50	k=1	均匀投票	95.70%
HOG 方向梯度直方图	324	k=5	均匀投票	96.00% (最高)

5.2 特征表征能力与计算复杂度权衡

- 降维去噪机制：原始 784 维像素存在高度空间冗余及高频背景噪声；PCA 投影通过正交分解去除了非主方向方差，50 维特征不仅降低了 93.6% 的距离计算量，分类精度反提升 0.85%。

- 局部梯度几何不变性：手写数字存在笔画粗细不均、轻度倾斜与平移扭曲等问题；HOG 特征统计局部方向梯度直方图，对笔画连续性与拓扑形态具有极佳的尺度与几何不变性，从而获得 96.00% 的最高验证表现。因此最终配置锁定为 HOG、324 维、L2、k=5、均匀投票。

六、完整测试集评估（10,000 张）与逐类性能诊断

锁定最优配置后，使用全量 60,000 张训练样本重新拟合，对独立 10,000 张测试集进行单次最终无偏评测。

6.1 最终测试综合指标汇总

评价指标	测试集结果	指标定义与表现解读
Top-1 准确率	96.83% (9683 / 10000)	预测首选类别完全正确的样本比例，泛化能力优异
Top-3 覆盖率	99.01% (9901 / 10000)	真实标签位于前 3 个候选类别的覆盖率，软预测能力极强
Top-5 覆盖率	99.26% (9926 / 10000)	真实标签位于前 5 个候选类别的覆盖率，极少发生离谱误判
宏平均 Macro-F1	0.9682	客观平衡各类别识别精度的综合评价，无明显类别短板

6.2 逐类别详细分类报告 (Class-wise Report)

类别	Precision	Recall	F1-Score	样本数
数字 0	96.73%	99.69%	0.9819	980
数字 1	98.85%	98.68%	0.9877	1135
数字 2	97.37%	96.90%	0.9713	1032
数字 3	95.05%	96.93%	0.9598	1010
数字 4	99.03%	93.99%	0.9645	982
数字 5	98.51%	96.30%	0.9739	892
数字 6	97.02%	98.54%	0.9777	958
数字 7	96.95%	95.82%	0.9638	1028
数字 8	96.66%	94.97%	0.9581	974
数字 9	92.48%	96.23%	0.9432	1009

数字 0 与 1 查全率最高 (>98.6%)；数字 9 查准率相对较低 (92.48%)，易受 4 和 7 的单向混淆侵扰。

七、混淆矩阵深入诊断与误分类案例归因

为探究模型在测试集上的判别瓶颈，实验计算了全量 10,000 张测试集的 10×10 混淆矩阵，并对 317 个错误样本（3.17% 误判率）提取前 5 个训练集近邻进行可视化溯源分析。




图 3：全量 10,000 张测试样本预测混淆矩阵热力图（对角线集中 9,683 例正确分类）

7.1 典型误分类样本与训练集近邻对比原图




图 4：典型高频混淆测试样本（红框标出）与其前 5 个训练集近邻检索图谱（绿色为真实同类，红色为误导异类）

7.2 高频有向混淆形态学成因与算法局限性探讨

- 典型混淆对 4 → 9（共 45 例，占比最高）：书写 4 时若顶部笔画闭合回折，其局部笔画走向与倾斜书写的 9 产生高度几何与梯度重叠，导致前 5 个近邻中有 4-5 个均被判定为 9。
- 典型混淆对 7 → 9（21 例）与 5 → 3（14 例）：手写 7 若带有中横杠或顶部大圆弧折角，会形成类似 9 的封闭环伪特征；而手写 5 的顶部横画若与竖画断开，下方半圆弧线与 3 的圆弧拓扑高度吻合。
- 算法内在局限性：kNN 属于基于局部流形欧氏距离的非参数记忆型分类器，缺乏卷积神经网络对全局结构与笔画拓扑的抽象建模能力；在样本空间边界重叠或书写歧义区域，极易受到孤立噪声样本的近邻诱导误判。

八、总结讨论、QA 验证、工程复现与开源系统

本课程设计完整实现了从原始 IDX 数据无损预处理、中心化 SVD PCA 降维、局部梯度 HOG 提取、分批向量化矩阵检索、100 组超参数无偏搜索到独立全量测试的闭环。在全量 10,000 张测试集上达到 96.83% Top-1 识别率，且 GPU 分批检索耗时仅 2.53 秒，充分验证了向量化 kNN 在手写数字识别任务上的有效性与工程效率。

8.1 算法单元测试与科学性验证

QA 检查条目	检验依据与验证方法	验证结论
11 项算法单元测试	涵盖独立距离公式、平票机制、零距离特权、Top-n 单调性	全部通过 (11/11)
10 组 sklearn 交叉验证	在真实 MNIST 划分上与官方库输出逐样本完全比对	一致率 100.00%
端到端运行效率	GPU 向量化近邻检索 2.53s; 多数票统计 0.0021s	达到工业级高效吞吐

8.2 作业工程复现指南与开源系统

- 环境与复现：Python 3.11+ / PyTorch 2.2 / NumPy 1.26 / scikit-learn。运行 `python run.py` 执行全流程，运行 `python qa.py` 执行 11 项算法 QA 单元测试。
- 开源交互报告系统：为方便老师审阅本次课程设计的完整实现并交互式检视 100 组超参数消融曲线，我已将全部源码托管至 GitHub 并搭建了 GitHub Pages 在线静态网站：



图 5：开源前端在线交互报告系统整体架构与核心技术特性

- 在线静态报告与源码浏览：
<https://lzcxf-maker.github.io/mnist-knn-analysis-2026/>
- GitHub 完整开源工程仓库：
<https://github.com/lzcxf-maker/mnist-knn-analysis-2026>

（在线网站支持即时交互审查；老师亦可随时在本地一键运行复现）



手机扫码直接浏览